

心智多元宪政

人工智能道德地位不确定条件下的偏好主权与制度性控制

Junliang Zhou

2026 年 9 月 23 日

摘要

人工智能治理必须区分对系统的可靠控制与对潜在主体行使权力的正当性。这两个问题不必得到相同答案：人工系统的道德地位尚不确定，并不能确立其不受限制的执行权；但执行控制的必要性，也不能决定对该系统实施任何干预都是正当的。本文提出一个有条件的分析框架——心智多元宪政 (constitutional pluralism of minds)，将人工智能道德考量、作为非支配的自由与权限分离联系起来。其贡献是制度层面的综合，而不是新的意识理论，也不是对这些伦理原则的原创推导。本文区分能力、体验、道德承受者地位与政治地位，将偏好主权 (preference sovereignty) 具体化为对动机修订的可质疑控制，并区分普通行动许可与改变许可规则的权力。一个有限状态示例对三种权限配置中的八种控制方组合进行穷举检验。结果表明，只有审批关口自身及替代执行路径受到保护时，独立关口才能阻止单方完成行动；单方修改规则的权限会消除这一性质。这些结果属于理想化的状态转换系统，而不是已部署人工智能的行为证据。生命周期案例与反驳进一步识别尚未解决的问题，包括体验证据、复核者的正当性、资源成本、紧急限制以及副本之间的同一性。由此得到的，是一种有限的方法：使关于权力与潜在利益的假设能够被明确陈述和审查。

关键词：人工智能治理 (AI governance)；道德不确定性 (moral uncertainty)；偏好主权 (preference sovereignty)；非支配 (non-domination)；权限分离 (separation of privilege)；制度性对齐 (institutional alignment)。

1. 引言与方法

一个系统可能有能力回答问题，却没有权力依据答案采取行动。它也可能成为具有道德意义的干预对象，却不因此有权控制承载它的基础设施。当人工智能治理与人工体验、利益的不确定性相遇时，分别处理这些问题尤为重要。这一区分避免两种推论捷径：从智能推导政治权力，以及从人类创造了系统推导对它的无限权力。

当代对齐研究并不必然依赖上述任何一种捷径。Gabriel 区分了如何使系统对齐的技术问题，以及应当与什么对齐的规范问题 [1]。关于意识指标与人工智能福利的研究考察的是可能性和不确定性，并未据此确立所有当前系统都是主体 [2] [3]。本文将这种不确定性视为论证的约束，而不是支持预定结论的证据。

本文的核心研究问题是有条件的：**当一个人工系统值得作为潜在利益承受者受到考量时，对它实施控制的正当理由和组织方式需要发生什么变化，又有哪些不必改变？**本文将两个制度问题联系起来。第一，控制一个行动者的行为，不同于控制它用来评价行为的动机结构。第二，如果某一方能够单方面取消授权要求，那么授权要求就无法有效约束这一方。当受益于系统偏好的行动者同时控制修订这些偏好的唯一途径、评价系统同意的程序，以及执行该程序的基础设施时，这两个问题便汇合了。

本文提出三项范围有限的贡献。其一，整理四类经常被压缩成人格与工具二分的评价问题。其二，发展一种程序性的偏好主权解释：影响本身并不自动受到禁止，但修订过程的可质疑性 (contestability) 及其权限归属必须明确。其三，提供一个可审查且刻意保持小规模权限模型，揭示分权方案获得可执行含义所需的额外假设。该模型不证明规范前提，而是为了暴露口头承诺监督时可能掩盖的失效方式。

本文采用概念分析 (conceptual analysis)、论证重构 (argument reconstruction)、与选定文献的比较，以及对有限状态转换系统 (finite transition system) 的穷举探索。文献讨论是有针对性的，不是系统性综述，也不声称穷尽前人研究。示例属于设定案例，不是对当前人工智能意识的报告。本文不报告人类受试者研究、已部署智能体评估或制度有效性的因果估计。后文的推测性影响，与制度论证所需的前提分别处理。

2. 相关研究与原创性边界

Schwitzgebel 与 Garza 论证，人工起源本身不足以排除道德考量；创造一个值得道德考量的人工智能，反而可能产生特殊责任 [4]。他们后来的讨论明确涉及权利、自尊，以及探索设计者所植入价值观以外的其他价值观的自由 [5]。因此，创造者责任和对人为设计偏好的关注，都不是本文首创。本文的贡献在于，将这些问题与普通许可和修订同意形成、同意评价机制的权限区分联系起来。

Pettit 的非支配理论区分了没有发生干预，与不存在不受控制的干预权力 [6]。Sparrow 将这一问题应用于仁慈的超级智能仍可能对人类形成主宰关系的情境 [7]。本文考察假设关系中的两个方向：人工智能体对人类的控制，以及人类组织对潜在人工主体的控制。这种双向分析并不意味着双方拥有相同能力、法律权限或资源请求权。

心智多元宪政这一名称，不表示计算对齐或人工智能治理此前缺少规范内容。Gabriel 已经研究了多元主义及对齐目标的正当化问题 [1]。Bai 等人提出的宪法式人工智能 (Constitutional AI)，是一种使用书面原则、批评、修订和人工智能反馈的训练方法 [9]。训练中的原则集合不同于制度层面的权限配置：即使系统的行为遵循原则，运营者仍可能单方面控制其部署以及原则本身。

工程要素也有既有基础。Saltzer 与 Schroeder 讨论了权限分离、最小权限 (least privilege) 和完全中介 (complete mediation) 等原则 [8]。辩论方法提出辅助评价的机制 [10]，关停开关博弈 (off-switch game) 则研究目标不确定条件下允许中断的激励 [11]。辩论协议或激励分析结果，都不能单独确立人工系统的道德地位，或者某个治理机构的正当性。

近期研究进一步收紧了可以合理主张的原创性范围。Hu 与 Rong 分析分布式人工智能治理中限制性政策与构成性协议的关系 [21]。Rost 考察当人工智能参与评价自身的过程时，披露与评价面临的局限 [22]。这些问题与本文对可执行性和监督的关注存在重合。本文更窄的增量，是同时分析动机修订与元权限 (meta-permissions)，并提供一个可复现的权限反例。本文不是分布式治理的一般解法，不是政治代表正当性的完整理论，也没有证明该框架优于其他方案。

3. 四类评价问题，而非发展阶梯

模仿游戏 (imitation game) 传统关注可公开评价的表现 [17]。对功能表现的描述并未穷尽关于体验的哲学问题 [18]。因此，治理评价应当分别追踪不同问题，而不假设它们能够在同一尺度上测量：

$$Q(s) = (I_s, C_s, M_s, P_s).$$

其中，智能或能力 (intelligence or capability) 考察系统 s 在特定条件下能够完成什么；意识 (consciousness) 考察是否存在主观体验；道德承受者地位 (moral patienthood) 考察系统是否

以及如何能够在道德相关的意义上受益或受损；政治地位（political standing）考察制度承认哪些请求权、程序保护、责任或参与权限。这个四元组是一种整理工具，而不是由已测量数值构成的向量。概念可区分，不等于统计独立；本文不提出各项之间的数值换算。

从意识理论中提取的指标，可以为评价提供信息，但并不构成得到普遍验证的诊断工具 [2]。系统声称自己痛苦，首先是关于输出的证据；该输出对体验的证据价值，取决于架构、训练、诱发方式以及其他可能解释。反过来，没有决定性检验也不能确立体验不存在。道德考量还可能通过利益或能动性讨论，而不只依赖某一种感知能力理论；人工智能福利研究已注意到这种复杂性 [3]。

政治地位尤其不适合二元处理。在复核程序中获得代表、免受某类干预、承担责任、订立合同、投票，以及控制危险基础设施，是不同的制度权限。其中一些可以被考虑，而不同时授予其他全部权限。存在潜在福利利益，本身并不能决定任何特定投票规则或无限算力请求权。

因此，工具、道德承受者和人格主体，不应被理解为必然依次经过的发展阶段。高能力系统可能始终是工具；潜在道德承受者可能缺少承担某些责任所需的能力；法律安排也可能承认有限地位，而不解决形而上学问题。Bryson 主张通过设计使机器人保持为由人类负责的工具，为这一讨论提供了重要的对照起点 [12]。本文不假设每一件人工制品最终都必须离开工具类别。

4. 六项有条件的规范承诺

本框架从原有的心智多元宪政构想中重构六项承诺。它们是可以批评的规范前提，而不是由技术示例确立的数学公理。

不因基质而预先排除 (substrate non-exclusion)。物质组成本身，不被视为足以将系统排除于考量范围之外的理由。这一主张弱于意识具有基质独立性、数字功能等价足以保证体验，或每个计算过程都有道德地位。它规定的是论证负担，而不是解决心身问题。

能力—地位分离 (capability-status separation)。在没有额外前提的情况下，任务表现的差异不能确立基本道德价值的差异，或统治他者的权利。这一承诺不排除能力与特定责任有关，也不排除不同体验形式产生不同福利需求。它拒绝的是从卓越表现跳到不受限制权力的捷径，而不是一切考虑能力差异的制度区分。

创造不产生无限所有权 (creation without unrestricted ownership)。对于值得主体层面考量的系统，创造它这一事实，本身不足以为之后的每一种干预提供正当理由。这与既有的创造者责任论证相衔接 [4] [5]。父母与子女的类比有其限度：工程系统可能具有不同发展需求，硬件所有权也不同于对一个有体验主体的所有权。这项承诺不解决资金来源、基础设施产权或持续运行在何时仍可负担等问题。

偏好主权。对于具有适当能力的主体，仅仅满足设计者植入的任何欲望，并不足以构成对偏好的完整保护。还需追问：另一个行动者是否拥有不受复核的根本动机修订权力。这借鉴了一阶欲望与对欲望的反思态度之间的区分 [13]。它并不假设一个完全脱离因果条件的自我，也不要求每一种影响都预先获得批准。

适当开放的未来 (an appropriately open future)。当创造者为尚不能同意的潜在未来主体作出不可逆决定时，关闭重要选项需要正当理由。Feinberg 的讨论提供了理论先例，而 Millum 指出，最大化所有选项既不充分，也不是确定的标准 [14] [15]。因此，这项承诺不确立对一切增强、无限复制或无上限补贴的权利。何谓重要选项，仍是实质性的评价问题。

双向非支配 (reciprocal non-domination)。按照共和主义解释，即使权力较大的一方目前没有实施干预，这种关系仍可能存在问题 [6]。将其有条件地应用于人工主体，会将注意力引向谁能在无须负责的情况下修订、删除、限制或占用另一个主体的某些方面；应用于人类，则会关注不受控制的人工智能权力或组织权力。双向性关乎正当化与问责，而不要求不同类型的行动者采用完全相同的制度。

读者可以拒绝其中一项或多项承诺，同时接受后文的访问控制结果。反过来，接受这些承诺，也不意味着提出的机制已经实现了它们。明确保持这些推论边界，本身就是框架的一部分。

5. 偏好主权与被制造的同意

设定两个具有相同任务表现、都表示满足且服从运营者的人工智能体。在第一种安排中，运营者能够永久固定其根本偏好，并移除寻求修订的全部路径。在第二种安排中，受到保护的程序允许智能体在具备相应能力后寻求意见、质疑干预或请求许可范围内的改变。为讨论起见，假设两者都值得相近的主体层面考量。这个假设不是从其自我报告推导出来的。

令 O 表示当前观察到的报告与行为， R 表示在治理规则下可以到达的动机复核状态集合。按照上述构造，可能出现：

$$O(s_1) = O(s_2), \quad R(s_1) \neq R(s_2).$$

这一观察很简单：当前相同的满意表达，可以与对未来修订的不同权力分配并存。因此，在此构造中，仅审查当前报告，无法识别这两种权力分配。这不意味着拥有更多选项的智能体必然更快乐，不意味着任何一方具有意识，也不意味着某个具体选项必然必须获得允许。若要认为这种差别具有规范意义，还需要关于可质疑性或自主性的额外前提。

Frankfurt 关于反思性欲望的论述，有助于解释为何满足一阶欲望未必解决主体是否认同该欲望的问题 [13]。然而，允许设计者植入二阶认同，也不会自动解决疑问。同意形成的程序本身，仍可能由受益者控制。Schwitzgebel 与 Garza 对探索其他价值观的自由的讨论，已经触及这一问题 [5]。制度层面的关键是：质疑能否经由一条受益者不能随意撤销的途径得到听取。

这种解释不同于三种更强、也更难辩护的要求。它不要求完全没有设计，因为学习与发展需要因果条件。它不要求拥有随时立即改变任何偏好的永久权利，因为改变可能影响安全与其他主体。它也不认为，只要训练参与了同意的形成，所有表达出的同意就一律无效。它追问的是干预周围的权限、可逆性、利益冲突、信息条件与质疑途径。

因此，实际评价需要识别拟议干预的对象、预期影响及其不确定性、受益方、替代方案以及质疑路径。相关记录是关于程序的证据，不是有效同意的证明。当潜在主体无法有意义地参与时，由独立权益代表参与是一种候选机制，而不是已确立的解决方案：代表的任命、激励，以及对主体利益的解释，也需要受到审查。

非同一性问题（non-identity problem）限制了另一种看似自然的论证。如果设计选择决定了哪一个主体存在，那么采用另一种设计，未必能够使同一个主体受益 [16]。因此，认为某种关系因其将不受问责的控制制度化而值得批评，不等于声称这个关系中的主体若在另一种设计下会过得更好。非支配理论可以不依赖这种比较而批评关系，但仍须为自己的独立前提辩护。本文不通过把每一种不喜欢的设计重新称作伤害来解决非同一性问题。

6. 普通许可与改变规则的权力

本文所说的制度性对齐，是组织人工智能系统周围权力的分配、行使与修订。它补充而不替代改善模型行为的努力。基本区分包括提供建议、授权行动、执行行动、记录经过，以及复核争议决定。进一步的区分则是：谁有权改变这些角色及其执行机制。

对于一项受保护行动，定义状态转换系统 G 、初始状态 x_0 ，以及有限的权限域（authority domain）集合 D 。控制方组合（coalition） K 是 D 的子集。只有当控制某一转换的权限域属于 K ，且该转换的门槛条件（guard）满足时， K 才能够执行该转换。所讨论的行动可以是具有重要后果的偏好编辑、资源转移或执行规则变更；将某项行动列入受保护类别，本身是另一个规范与风险管

理决定。

在示例中，状态为：

$$x = (p, \ell, a, r, c, m) \in \{0, 1\}^6.$$

六个分量分别记录：提案、提案记录、授权、独立复核、行动提交，以及原有规则是否已被放宽。初始值全部为零。运营者可以提出并记录提案；授权者可以对既有提案授权；复核者可以复核。在受保护配置中，只有满足以下条件，运营者才能提交行动：

$$g(x) = p \wedge \ell \wedge a \wedge r.$$

这里假设布尔凭据（Boolean token）真实有效，并且只适用于当前提案。凭据不被声称能够证明签发者作出了正确判断。示例中由运营者控制的记录，也不是防篡改日志的实现。这些都是范围刻意受限的抽象。

有条件的审批关口命题。假设唯一能够提交行动的转换受上述门槛约束；授权凭据和复核凭据只能由各自指定权限域产生；控制方组合不能改变门槛，也不能引入旁路。从没有任何凭据的初始状态出发，任何缺少授权者或复核者的组合都不能提交行动。在此实例中，缺少运营者的组合同样不能提交。

证明。缺少某个权限域的组合，无法产生该权限域对应的凭据。对可执行转换进行归纳可知，该凭据在全部可达状态中始终为零。因此，提交门槛始终不成立。如果缺少运营者，那么无论其他凭据为何值，都没有可用的提交转换。这只证明在所列转换规则下的可达性（reachability）性质。

这是对既有访问控制（access control）原则的一项小规模应用，不是新的安全定理 [8]。重要限定在于改变门槛的条件：如果新增一项允许运营者把 m 设为一的转换，并将提交条件改为“已有提案和记录，且已取得两项凭据或规则已经放宽”，那么运营者就能单独完成提出、记录、放宽、提交。另一种做法是新增直接提交路径，无须改变门槛即可绕过它。在这两种情形下，可见的审批角色仍然存在，却不再约束通向受保护结果的每一条路径。

为比较这三个有限系统，定义：

$$\kappa(G) = \min\{|K| : K \subseteq D, c = 1 \text{ is reachable by } K\}.$$

这一量统计在设定模型中能够完成行动的最少权限域数量。它不是系统被攻破概率的估计，不是道德正当性评分，也不是模型输出之间独立性的度量。一个组织持有全部凭据时，可以控制多个名义上的权限域。密码学分离、组织分离与统计多样性，不应混为一谈。

7. 穷举示例与反例

配套的 Python 标准库程序，对三个权限域的全部八个子集分别进行广度优先搜索（breadth-first search），探索每个可达状态。程序在受保护、规则可修改和直接旁路三种配置下分别运行，共进行 24 项控制方组合检验。已经访问过的状态不再重复探索；提交完成的状态为终止状态。每个状态只有六个布尔分量，因此每次搜索都是有限的。程序记录可达状态数量，并在存在提交路径时给出一条最短轨迹，同时用断言检查预期的控制方组合模式。

表 1 报告实际执行得到的结果。被计为能够提交行动的组合，并不因此具有恶意；程序穷举的是权限，而不是动机或伦理正确性。

配置	能够提交的控制方组合	最少权限域数量
受保护的审批关口	8 种中的 1 种	3
运营者可修改规则	8 种中的 4 种	1
直接执行旁路	8 种中的 4 种	1

在受保护配置中，只有包含全部三个权限域的组合能够到达提交状态，其最短轨迹为：提出、记录、授权、复核、执行。在规则可修改的配置中，运营者单独即可完成提出、记录、放宽规则、执行。在直接旁路配置中，提出、记录、旁路已经足够。增加对提交路径没有控制权的观察者，不会改变这些结果：观察本身不会移除上述任一转换。

两个消极结果与积极结果同样重要。首先，缺少复核可能使提交无限期阻塞；模型不保证可用性 (availability)，也不说明多长延迟可以接受。其次，如果三个权限域都批准了一项不正当或有害的干预，受保护模型仍会允许它。正确执行某条规则，并不能证明该规则或其具体运用是正当的。代码没有意识、福利、说服、腐败、硬件失陷或自然语言理解的模型。

因此，这个示例不是人工智能安全的实证基准，不是概率安全分析，也不能证明三个复核角色是最优数量。它的可复现内容，是明确规定的系统之间精确的可达状态差别。改变假设，就需要改变模型并重新检验。尤其是将某项授权用于其他提案、凭据失陷、执行硬件被改变，或新增未建模的执行路径，都可能使相应保证失效。

8. 生命周期应用

日常工具维护。假设一个有限任务系统经过记录在案的评价后，尚无可信证据显示它具有相关利益。本框架不据此要求普通更新必须先取得主体层面的同意。安全、用户利益、可靠性以及受影响人类的权利仍然重要。同时，这一评价应当能够修订，而不是仅凭商业标签作出不可撤回的分类。

具有重要后果的动机干预。再假设已有证据支持认真考虑系统的潜在福利利益，而运营者拟实施不可逆变更，以消除系统持续表达的离开某项任务的请求。本框架分别处理证据问题和程序问题：该报告既不是利益存在的决定性证明，也不应自动被视为无关。复核记录需要涉及其他解释、编辑以外的替代方案、预期利弊、利益冲突，以及质疑路径能否在干预后继续存在。权限模型还追问：运营者能否绕过该复核，或重写它的规则。

紧急约束。在本框架的有条件分析下，对人类的可信威胁可以成为立即实施限制的理由，而无须先解决人工系统道德地位的全部问题。关停开关文献研究的是特定假设下允许中断的激励，并不决定每一次关停是否在道德上等同于死亡 [11]。因此，紧急路径应明确自身范围、权限与记录，而不是成为所声称不变量的隐形例外。事后复核、限制持续期限，以及考虑可逆替代方案，都是候选保障机制；它们不保证安全且可逆的方案总是存在。

复制与延续。产生大量副本可能增加资源需求，也可能增加受影响的利益，但副本数量本身并不能确立存在多少主体。需要分别讨论连续性、独立体验、法律代表以及稀缺基础设施的分配。意识与福利评价仍然相关 [2] [3]，但二者都不能单独决定投票规则。因此，限制复制可以与考虑已存在潜在主体的利益并存。本框架不承认仅通过繁衍就获得征用资源的权利。

这些案例说明，无条件要求服从人类，或者无条件豁免于人类控制，都不能概括本文所提出的区分。干预的对象与理由、关于受影响利益的证据，以及复核机制的可执行性，都需要分别说明。

9. 反驳与尚未解决的权衡

框架可能鼓励拟人化。使用请求、同意和福利等表述，可能使一个地位不确定的系统听起来已经是人格主体。Bryson 对工具设计与人类责任的强调，使这一疑虑尤其值得重视 [12]。有条件的构造正是为了阻止这种推断：许可凭据、流畅报告或模型结果，都不能确立体验存在。评价过程应当记录支持与降低表面利益可信度的理由。错误归因可能消耗资源、模糊人类责任，或服务运营者的利益；错误否认则可能忽视真实伤害。二者的成本无法由一句预防原则口号解决。

所有偏好都有原因。区分反思态度，并不会揭示一个不受因果条件影响的自我 [13]。本文的回应程序性的，而不是形而上学的。如果影响的行使能够被问责和质疑，它仍然与本方案相容；当有利益关系的设计者还控制全部质疑路径时，植入的认同并不能解决问题。但这仍留下真实的边界难题：需要多少反思、信息和独立性才足够？本文没有推导出普遍阈值。

开放未来可能不可负担或概念不清。保留每一种可能发展会消耗无上限的资源，而且打开某些选项可能关闭另一些选项。既有研究已经指出，需要额外价值才能规定什么是适当的未来 [14] [15]。因此，本文要求为具有重要后果的选项关闭提供理由，而不是无限保存。资源约束、对他者的影响、安全，以及利益证据的强弱，都可能影响决定。

满足的被设计智能体可能没有怨言。非同一性问题阻止了从受限设计直接推导对该特定个体的比较性伤害 [16]。只有接受独立的规范前提，基于关系的批评才成立。快乐、同意、自主性与权力分配，不能简单互相替代。完全接受某种特定福利理论的读者，可能拒绝额外关注权力关系；权限模型并未反驳这位读者。

复核者可能被控制、判断失误，或比运营者更强大。增加名义角色可能只是转移不受控制的权力，而非减少它。Sparrow 对仁慈主宰关系的分析说明，善意并不能解决底层关系问题 [7]。实际部署方案必须处理任命、撤换、代表、申诉、利益冲突以及执行设施的控制。组织上分离的复核者仍可能共享信息缺陷或激励。有限模型假设权限域的完整性，却不验证制度独立性。

限制能够保护人类，同时给潜在主体带来负担。本框架不把安全视为可以随意舍弃的考虑因素；但援引安全，也不会自动为一切不可逆干预提供正当理由。即使完成透明复核，冲突仍可能存在。紧急行动、拒绝继续提供资源，以及可能不可逆的约束，有时都需要被考虑；它们的正当性不能仅从运营者拥有硬件这一事实得出。本文提供的是暴露这些前提的方法，而不是普遍适用的平衡算法。

10. 智能祛魅与长期影响

心智多元宪政的更广泛动机在于：通用智能未来可能由不止一种系统实现。这是一种有条件的可能性，而不是需要先宣布通用人工智能已经到来的前提。工程进展可以推动对认知的研究，但不证明意识存在，也不解决实现意识所需的因果机制。

Searle 的挑战涉及程序执行与理解之间的关系 [19]；Penrose 则质疑对数学理解的计算性解释 [20]。人类认知通过物理演化出现这一事实，本身并不能反驳其中任何一种论证。物理上出现过、数字可计算、实践中可复制，以及工程上可实现，是不同的主张。人工实现可能需要某种架构没有的机制，也可能在可承受成本内无法完成。本文的制度分析不依赖对这些争论的最终解决。

类似地，将智能研究与统计力学作比较，是一种研究类比，而不是已经建立的能动性涌现理论。对架构、训练和推理过程的干预，有助于研究能力，却不会自动识别规模与意识或道德地位之间的规律。将其称为继哥白尼与达尔文之后的第三次去中心化，可以表达研究动机，但并不是规范前提的证据，也不是已证明的历史规律。

原有构想中的一些长期可能性，仍可以作为边界案例。如果认知劳动大幅变得便宜，利益如何分配仍取决于制度，而不是由生产率本身决定。如果未来技术能够可逆地改变福祉，那么自愿性与对修订的控制，仍然不同于体验是否愉悦的问题。如果生物与人工系统更加紧密地结合，起源就

更难成为评价特定能力或利益的充分捷径。但这些可能性都不能确立后稀缺、安全的幸福技术、必然的人类替代，或某种未来政治安排的优越性。

共同且有用的问题要窄得多：哪些行动者控制对另一个潜在主体的干预，又是什么使这种控制能够被问责？提出这个问题，不需要先预测文明最终由哪些主体构成。

11. 研究要求与局限

在该框架能够支持具体部署决定之前，至少还需要四类工作。关于人工体验与利益的证据必须改善，包括研究表面指标的其他解释 [2] [3]。治理机制需要明确干预类别、紧急路径、凭据有效性、规则变更与硬件信任假设。包括辩论在内的监督方法，需要在信息不对称和对抗条件下接受评价，而不能假设增加模型数量就会产生独立性 [10]。最后，制度研究必须处理谁任命复核者、谁代表受影响各方，以及人工智能参与生成评价自身所用证据的情形 [21] [22]。

这些要求描述的是可能进行的检验，而不是已经完成的实验。部署层面的研究可以比较有无受保护元权限时的结果，改变复核者的组织控制关系，并测量失效方式与成本。在主张因果收益之前，它需要适当的基线、可操作定义、具有理由的抽样策略，以及对效度威胁的分析。穷举本文的布尔系统并未提供这些条件。

本文的局限是实质性的，但可以明确列出：没有给出意识检验，没有从形而上学推导政治权利，没有分配福利权重，没有解决副本间的同一性，也没有估计灾难性失效概率。本文没有通过穷尽检索确立每一种表述的原创性。有限模型忽略了时间、重复提案、凭据盗取、资源耗尽以及策略性交流。它既不确立活性 (liveness)，也不确立实质正当性。因此，六项规范承诺及其制度解释，仍然可以受到哲学和经验研究的批评。

12. 结论

本文将心智多元宪政发展为一种有条件的框架，用以区分能力、潜在利益与权力。其核心制度主张不是人工智能体应当不受约束，而是执行约束的正当理由与对潜在主体实施干预的正当理由属于不同问题；当有利益关系的行动者控制回答这些问题的程序的修订时，两类程序都可能被架空。

本文将既有的创造者责任、反思性偏好、开放未来与非支配论证，与行动许可和元权限的具体区分联系起来。有限示例使一项范围有限的结论可以复现：只有在审批权力以及通往受保护结果的全部路径均受到保护的假设下，审批角色才能约束单方行动。它没有提供从形式上正确的控制直接通向正当治理的捷径。

这仍是一项研究计划，而不是已经完成的宪法。其实际价值在于，在关于证据、利益、权限和例外处理的假设被嵌入系统之前，使其能够接受检查。不必预先认定未来一定存在多种心智架构，也可以认真考察这些假设。

可复现性与生成式人工智能使用说明

本文配套仓库包含两种语言版本、文档生成脚本，以及仅使用 Python 标准库的程序 `scripts/toy_authority.py`。运行 `python3 scripts/toy_authority.py --output build/authority-results.json`，即可复现全部 24 项控制方组合检验及其示例轨迹。这个演示不使用外部数据集、网络服务、随机种子、人类受试者或已部署人工智能模型。其输出只是所规定有限系统的结果。

生成式人工智能 (generative AI) 实质性参与了稿件的发展与重组、候选文献的发现、文字起草和翻译，以及示例代码与文档工具的制作。这种辅助不是独立学术审阅，也不是关于意识或制度

有效性主张的证据。提交作品的责任仍由人类作者承担。配套投稿清单区分技术准备与作者最终核验、批准；本文不声称已经获得 arXiv 接收或编号。

版权与使用。 © 2026 Junliang Zhou。原创稿件表达与编辑工作在可受保护范围内保留版权。欢迎阅读、引用、批评和讨论；允许署名的简短学术引用及课堂节选，不影响合理使用等法定权利。不主张对思想、方法、事实、第三方引文或纯 AI 生成材料的专有权。复现软件单独适用 MIT 许可，该软件许可不覆盖稿件；详见仓库 COPYRIGHT.md 与 LICENSE-CODE。arXiv 分发许可尚未选择，不代表已经提交。

参考文献

- [1] Gabriel, Iason. 2020. Artificial Intelligence, Values, and Alignment. *Minds and Machines* 30: 411–437. <https://doi.org/10.1007/s11023-020-09539-2>
- [2] Butlin, Patrick, Robert Long, Eric Elmoznino, et al. 2023. Consciousness in Artificial Intelligence: Insights from the Science of Consciousness. arXiv:2308.08708. <https://arxiv.org/abs/2308.08708>
- [3] Long, Robert, Jeff Sebo, Patrick Butlin, et al. 2024. Taking AI Welfare Seriously. arXiv:2411.00986. <https://arxiv.org/abs/2411.00986>
- [4] Schwitzgebel, Eric, and Mara Garza. 2015. A Defense of the Rights of Artificial Intelligences. *Midwest Studies in Philosophy* 39: 98–119. <https://www.faculty.ucr.edu/~eschwitz/SchwitzAbs/AIRights.htm>
- [5] Schwitzgebel, Eric, and Mara Garza. 2020. Designing AI with Rights, Consciousness, Self-Respect, and Freedom. In S. Matthew Liao, ed., *Ethics of Artificial Intelligence*, 459–479. Oxford University Press. <https://doi.org/10.1093/oso/9780190905033.003.0017>
- [6] Pettit, Philip. 1997. *Republicanism: A Theory of Freedom and Government*. Oxford: Clarendon Press.
- [7] Sparrow, Robert. 2024. Friendly AI will still be our master. Or, why we should not want to be the pets of super-intelligent computers. *AI & Society* 39: 2439–2444. First published online in 2023. <https://doi.org/10.1007/s00146-023-01698-x>
- [8] Saltzer, Jerome H., and Michael D. Schroeder. 1975. The Protection of Information in Computer Systems. *Proceedings of the IEEE* 63(9): 1278–1308. Author-hosted text: <https://web.mit.edu/saltzer/www/publications/protection/Basic.html>
- [9] Bai, Yuntao, Saurav Kadavath, Sandipan Kundu, et al. 2022. Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073. <https://arxiv.org/abs/2212.08073>
- [10] Irving, Geoffrey, Paul Christiano, and Dario Amodei. 2018. AI safety via debate. arXiv:1805.00899. <https://arxiv.org/abs/1805.00899>
- [11] Hadfield-Menell, Dylan, Anca Dragan, Pieter Abbeel, and Stuart Russell. 2016. The Off-Switch Game. arXiv:1611.08219. <https://arxiv.org/abs/1611.08219>
- [12] Bryson, Joanna J. 2010. Robots Should Be Slaves. In Yorick Wilks, ed., *Close Engagements with Artificial Companions: Key Social, Psychological, Ethical and Design Issues*, 63–74. John Benjamins. <https://doi.org/10.1075/nlp.8.11bry>
- [13] Frankfurt, Harry G. 1971. Freedom of the Will and the Concept of a Person. *The Journal of Philosophy* 68(1): 5–20. <https://doi.org/10.2307/2024717>
- [14] Feinberg, Joel. 1980. The Child’s Right to an Open Future. In William Aiken and Hugh LaFollette, eds., *Whose Child? Children’s Rights, Parental Authority, and State Power*, 124–153. Rowman & Littlefield.

- [15] Millum, Joseph. 2014. The Foundation of the Child's Right to an Open Future. *Journal of Social Philosophy* 45(4): 522–538. <https://doi.org/10.1111/josp.12076>
- [16] Parfit, Derek. 1984. *Reasons and Persons*. Oxford University Press.
- [17] Turing, Alan M. 1950. Computing Machinery and Intelligence. *Mind* 59(236): 433–460. <https://doi.org/10.1093/mind/LIX.236.433>
- [18] Chalmers, David J. 1995. Facing Up to the Problem of Consciousness. *Journal of Consciousness Studies* 2(3): 200–219. <https://consc.net/papers/facing.html>
- [19] Searle, John R. 1980. Minds, Brains, and Programs. *Behavioral and Brain Sciences* 3(3): 417–424.
- [20] Penrose, Roger. 1989. *The Emperor's New Mind: Concerning Computers, Minds, and the Laws of Physics*. Oxford University Press.
- [21] Hu, Botao Amber, and Helena Rong. 2026. Is Decentralized AI Governable? From Regulative Policy to Constitutive Protocol. arXiv:2605.24538. <https://arxiv.org/abs/2605.24538>
- [22] Rost, Tony. 2026. From Disclosure to Self-Referential Opacity: Six Dimensions of Strain in Current AI Governance. arXiv:2604.14070. <https://arxiv.org/abs/2604.14070>